# Gemma-4 E2B 零样本目标检测评测与跨范式对比分析

Zero-Shot Object Detection with Gemma-4 on Pascal VOC 2007

**种子 2301 席佳伟**

2026 年 4 月 20 日

**摘要**

视觉语言模型 VLM 的快速发展正在改变目标检测的范式。传统检测器依赖大量标注数据进行有监督训练，而 VLM 通过预训练阶段积累的视觉-语言对齐能力，有望实现零标注成本的目标检测。本报告评测 Google Gemma 4 系列最小模型在 Pascal VOC 2007 上的零样本检测性能。

我使用有效参数为 2.3B 的 Gemma-4 E2B-it 对 VOC 2007 test 全部 4952 张图进行零样本推理，不做任何微调。设计了包含 prompt 工程、三级容错 JSON 解析、坐标转换、类别模糊匹配和 token log-prob 置信度评估在内的完整评测管线。使用与 PLN 复现项目完全一致的 `voc_eval.py` 计算 mAP@0.5，确保跨范式对比的公平性。

Gemma-4 E2B 取得 **51.51%** mAP@0.5（mAP@0.75 = 30.05%），推理成功率 99.5%。与使用完整有监督训练的 PLN-ResNet18（68.74%）相差 17.23 个百分点。逐类对比揭示 VLM 在语义特征鲜明的大物体上（cat 90.89%）可超越专用检测器，但在小目标和密集实例上存在系统性短板。错误分析表明，29.7% 的 GT 漏检和 16.8% 的背景误检（幻觉）是主要的性能瓶颈，而非定位精度本身。两种范式在能力维度上呈现互补特征：有监督检测器擅长精确空间定位，VLM 擅长语义理解和零样本泛化。

## 目录

**1 引言** **3**
1.1 任务背景 . . . . . 3
1.2 零样本检测的意义 . . . . . 3

**2 方法设计** **3**
2.1 Prompt 设计 . . . . . 3
2.2 输出解析 . . . . . 4
2.2.1 Markdown fence 去除 . . . . . 4

2.2.2 三级容错 JSON 解析 . . . . . 4
2.2.3 坐标转换 . . . . . 4
2.2.4 类别模糊匹配 . . . . . 5
2.3 置信度评估 . . . . . 5
2.4 评测协议 . . . . . 5

**3 实验结果** **6**
3.1 总体指标 . . . . . 6
3.2 各类 AP 结果 . . . . . 6
3.3 类别分析 . . . . . 6
3.4 IoU 阈值敏感性分析 . . . . . 7
3.5 错误模式分析 . . . . . 7
3.6 推理可靠性 . . . . . 8

**4 跨范式对比：Gemma-4 E2B vs PLN-ResNet18** **8**
4.1 总体对比 . . . . . 9
4.2 逐类 AP 对比 . . . . . 9
4.3 对比分析 . . . . . 11
4.4 范式差异的本质 . . . . . 11

**5 讨论** **12**
5.1 51.51% 零样本 mAP 的位置 . . . . . 12
5.2 瓶颈分析 . . . . . 12
5.3 潜在改进方向 . . . . . 13

**6 结论** **13**

**A 实验环境** **14**

# 1 引言

## 1.1 任务背景

在上一个任务中，我复现了 Point Linking Network，将 Backbone 从 Inception-v2 替换为 ResNet-18，在 VOC 2007 Test 上取得 68.74% mAP@0.5。第二阶段的任务是：使用 Gemma 4 最小模型，在同一数据集上评测零样本 mAP。

两个阶段使用同一数据集、同一评测指标、同一份 `voc_eval.py` 评测代码，目的是希望**在同一把尺子下量化”有监督专用检测”与”零样本通用检测”的差距**，建立对目标检测范式演进的直观认知。

## 1.2 零样本检测的意义

传统目标检测的工作流程是：收集数据 → 标注边界框 → 训练模型 → 部署推理。其中数据标注是最大的成本瓶颈——VOC 2007+2012 的 16k 张标注图在今天看来规模很小，但 COCO 的 120k 张标注成本已经相当可观，而自动驾驶场景的标注成本更是量级级的增长。

VLM 的零样本检测提供了一种完全不同的路径：模型在大规模图文数据上预训练后，无需任何任务特定标注，仅通过自然语言 prompt 即可执行检测。这种能力的实用价值在于：

- **零标注成本**：新类别、新场景无需重新标注和训练
- **开放词汇**：不受预定义类别集的限制
- **快速原型验证**：无需训练流程即可评估检测可行性

代价同样明确：精度不如专用检测器，推理速度慢两个数量级。我核心目标就是量化这些 trade-off。

# 2 方法设计

## 2.1 Prompt 设计

```
Detect all objects in this image that belong to these categories:
aeroplane, bicycle, bird, boat, bottle, bus, car, cat, chair, cow,
diningtable, dog, horse, motorbike, person, pottedplant, sheep, sofa,
train, tvmonitor.
For each detected object, output a JSON list where each element has
"box_2d" (as [y_min, x_min, y_max, x_max] in range 0-1000) and "label"
(the category name). Only output the JSON list, nothing else.
```

设计要点：

1. **显式列出全部 20 类**：避免模型遗漏类别或输出非 VOC 类别名称。
2. **指定 `box_2d` 格式**：这是 Gemma 4 原生训练的检测输出格式（1000×1000 归一化坐标空间），使用模型训练时的原生格式可以最大化检测质量。
3. **要求纯 JSON 输出**：减少解析复杂度。实际测试中模型仍会包裹 markdown code fence（```` ```json ... ``` ```），需在解析前去除。

## 2.2 输出解析

模型的自回归文本输出需要经过多级处理才能转化为标准检测框。

### 2.2.1 Markdown fence 去除

Gemma 4 常将 JSON 包裹在 ```` ```json ... ``` ```` 中。使用正则表达式在 JSON 解析前去除：

```
text = re.sub(r"^```(?:json)?\s*\n?", "", text.strip())
text = re.sub(r"\n?```\s*$", "", text.strip())
```

### 2.2.2 三级容错 JSON 解析

表 1: 三级容错解析策略

| 级别 | 策略 | 实际命中率 |
|---|---|---|
| L1 | 直接 `json.loads()` 解析整段输出 | >99% |
| L2 | 正则提取 JSON 数组 `[{...}, ...]` | <1% |
| L3 | 逐个提取 JSON 对象 `{...}` | 极少触发 |

L1 的高命中率说明 Gemma 4 E2B 的指令遵循能力已经相当稳定。三级设计是防御性编程，确保即使模型输出格式异常也能最大限度地提取有效信息。

### 2.2.3 坐标转换

Gemma 4 输出 `box_2d` $= [y_{\min}, x_{\min}, y_{\max}, x_{\max}]$，坐标空间为 0–1000 归一化整数，需转换为 VOC 标准的 $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$ 像素坐标：

$$x_{\text{pixel}} = \frac{x_{1000}}{1000} \times W, \quad y_{\text{pixel}} = \frac{y_{1000}}{1000} \times H \tag{1}$$

转换后对框进行合法性校验（正面积），丢弃退化框。

#### 2.2.4 类别模糊匹配

VLM 输出的类别名可能与 VOC 标准名不一致。通过三级匹配解决：

1. **精确匹配**：`dog` → `dog`
2. **别名表查找**:维护 30+ 条映射,如 `airplane` → `aeroplane`,`motorcycle` → `motorbike`，`tv` → `tvmonitor`
3. **子串匹配兜底**：如 `dining table` → `diningtable`

### 2.3 置信度评估

传统检测器直接输出每个框的 confidence score。VLM 的自回归生成没有这一概念，本项目使用 **token log-probability 的几何平均值**作为序列级置信度：

$$\text{confidence} = \exp\left(\frac{1}{T}\sum_{t=1}^{T}\log p(x_t \mid x_{<t})\right) \tag{2}$$

其中 $T$ 为生成的 token 数量。该分数反映模型对整段输出的" 确定性"，用于 VOC mAP 计算中 precision-recall 曲线的排序。

需要注意的是，这是一个**序列级**而非**框级**的置信度——同一张图上的所有检测框共享同一个 score。这是 VLM 做检测的固有限制：框是序列生成的一部分，无法为每个框独立打分。

### 2.4 评测协议

表 2: 评测配置

| 项目 | 配置 |
|---|---|
| 数据集 | Pascal VOC 2007 test（4952 张，12032 个非 difficult GT 框） |
| 指标 | mAP@IoU=0.5（11-point interpolation） |
| 评测代码 | `voc_eval.py`（与 PLN 项目完全一致） |
| GPU | NVIDIA RTX 4090 (24GB VRAM) |
| 精度 | BF16 |
| 解码策略 | Greedy（`do_sample=False`） |
| 最大生成长度 | 2048 tokens |
| 断点续传 | 每 50 张保存 checkpoint |

# 3 实验结果

## 3.1 总体指标

表 3: Gemma-4 E2B 零样本检测总体结果

| 指标 | 数值 |
|---|---|
| **mAP@0.5** | **51.51%** |
| 总检测框 | 13,191 |
| 总 GT 框 | 12,032 |
| 平均检测数/张 | 2.7 |
| 推理成功率 | 99.50% (4927/4952) |
| 解析失败 | 1 张 (0.02%) |
| 无检测输出 | 24 张 (0.48%) |
| 平均推理时间 | 4.37 s/张 |
| 总推理时间 | 360.9 min |

## 3.2 各类 AP 结果

表 4: VOC 2007 Test 全 20 类 AP（Gemma-4 E2B, Zero-shot）

| 类别 | AP (%) | 类别 | AP (%) | 类别 | AP (%) |
|---|---|---|---|---|---|
| cat | **90.89** | dog | 82.70 | train | 70.55 |
| horse | 66.61 | cow | 65.11 | bird | 63.71 |
| bus | 61.72 | bicycle | 61.19 | motorbike | 59.86 |
| sheep | 57.84 | person | 53.30 | car | 51.87 |
| aeroplane | 50.55 | tvmonitor | 39.79 | sofa | 36.24 |
| chair | 27.53 | diningtable | 25.08 | boat | 24.86 |
| bottle | 24.00 | pottedplant | 16.86 | | |
| **mAP = 51.51%** | | | | | |

## 3.3 类别分析

**第一梯队（AP > 60%）:** cat (90.89%), dog (82.70%), train (70.55%), horse (66.61%), cow (65.11%), bird (63.71%), bus (61.72%), bicycle (61.19%)。共性特征是物体通常较大、形态特征鲜明、在互联网图像中出现频率高。cat 的 90.89% 说明 VLM 对这类高辨识度目标的检测能力已经非常强。

**第二梯队（AP 40–60%）：** motorbike (59.86%), sheep (57.84%), person (53.30%), car (51.87%), aeroplane (50.55%)。person 虽然是最高频类别（约占 GT 的 1/4），但 AP 仅 53.30%，主要原因是密集场景下 VLM 难以逐个输出所有实例。

**第三梯队（AP < 40%）：** tvmonitor (39.79%), sofa (36.24%), chair (27.53%), diningtable (25.08%), boat (24.86%), bottle (24.00%), pottedplant (16.86%)。弱势类别的共

性包括：小目标（bottle, pottedplant），边界模糊的家居物品（chair, diningtable, sofa），以及密集远景目标（boat）。

## 3.4 IoU 阈值敏感性分析

传统检测器的评测通常只报告 mAP@0.5，但这一阈值对定位精度的要求较低。为全面评估 VLM 的空间定位能力，本节在多个 IoU 阈值下重新计算 mAP。

表 5: 不同 IoU 阈值下的 mAP

| **IoU 阈值** | 0.50 | 0.60 | 0.70 | 0.75 | 0.80 | 0.90 |
|---|---|---|---|---|---|---|
| **mAP (%)** | 51.51 | 44.78 | 35.30 | 30.05 | 23.98 | 11.60 |

从 mAP@0.5 到 mAP@0.75，性能下降了 **21.46 个百分点**（51.51% → 30.05%），降幅达 41.7%。作为对比，成熟的有监督检测器（如 Faster R-CNN）从 mAP@0.5 到 mAP@0.75 的降幅通常在 15–25% 左右。这证实了 VLM 检测的核心短板在于**空间定位精度**而非语义识别能力。

逐类来看，cat 从 90.89%@0.5 降至 79.55%@0.75（降幅 12.5%），仍然保持在高水平；而 boat 从 24.86% 暴跌至 6.68%（降幅 73.1%），pottedplant 从 16.86% 降至 5.02%（降幅 70.2%）。大物体的定位精度显著优于小物体，这符合 2.3B 模型视觉编码器分辨率有限的预期。

## 3.5 错误模式分析

为进一步理解 mAP 损失的来源，我将全部 13,191 个检测框按错误类型进行分类：

表 6: 检测错误类型分布

| 错误类型 | 数量 | 比例 |
|---|---|---|
| 正确检测（TP, IoU≥0.5） | 8,456 | 64.1% |
| 定位误差（正确类别, 0.1≤IoU<0.5） | 1,638 | 12.4% |
| 背景误检（IoU<0.1, 幻觉） | 2,220 | 16.8% |
| 其他误检（类别混淆等） | 811 | 6.1% |
| 重复检测（GT 已匹配） | 66 | 0.5% |

同时，在 12,032 个 GT 框中：

表 7: GT 框召回情况

| 状态 | 数量 | 比例 |
|---|---|---|
| 成功召回（被正确检测匹配） | 8,456 | 70.3% |
| 漏检（FN, 未被任何检测匹配） | 3,576 | 29.7% |

**关键发现：**

1. **定位误差（12.4%）不是主要问题**。这些框检测到了正确的物体类别，但框的精度不足（IoU 在 0.1–0.5 之间）。如果 IoU 阈值放宽到 0.1，大部分会变为 TP。
2. **背景误检（16.8%）是最大的 FP 来源**。2,220 个检测框与所有 GT 的 IoU 均低于 0.1，本质上是" 幻觉"——模型生成了场景中不存在的物体框。其中 chair（440）、sofa（361）和 diningtable（290）是重灾区，说明模型对室内家具类物体的边界判断极不稳定。
3. **漏检（29.7%）是 mAP 损失的主因**。3,576 个 GT 框未被检测到。漏检最严重的类别是 person（1,278 个漏检，占 person GT 的 28.2%）、car（372）和 pottedplant（296）。这与自回归生成的" 提前终止" 倾向一致——密集实例场景中，模型倾向于只输出最显著的目标。
4. **sofa 的反常表现：**sofa 的召回率高达 89.1%（仅漏检 26 个），但 AP 只有 36.24%。原因是 sofa 产生了 361 个背景误检（远超正确检测数 213），大量误检严重拉低了 precision。

### 3.6 推理可靠性

表 8: 输出分类统计

| 输出类型 | 数量 | 比例 |
|---|---|---|
| success（解析出有效检测框） | 4927 | 99.50% |
| no_detection（模型认为无目标） | 24 | 0.48% |
| parse_failure（输出格式异常） | 1 | 0.02% |
| empty_output（推理异常） | 0 | 0.00% |

4952 张图中仅 1 张解析失败（0.02%），证明 Gemma 4 E2B 的指令遵循能力非常稳定。

## 4 跨范式对比：Gemma-4 E2B vs PLN-ResNet18

两个阶段使用同一数据集（VOC 2007 test）、同一评测代码（`voc_eval.py`）、同一指标（mAP@0.5），使对比具有严格的可比性。

## 4.1 总体对比

表 9: 两种检测范式的全面对比

| 维度 | PLN (ResNet-18) | Gemma-4 E2B (Zero-shot) |
|---|---|---|
| mAP@0.5 | **68.74%** | 51.51% |
| mAP@0.75 | — | 30.05% |
| 训练数据 | VOC 07+12 trainval (∼16k 张) | 无（零样本） |
| 模型参数 | 165M (Backbone 11.7M) | 2.3B 有效 / 5.1B 总 |
| 推理速度 | ∼30 ms/张 | 4370 ms/张 |
| 速度比 | 1× | ∼145× 慢 |
| 范式 | CNN + 关键点回归 | VLM 自回归生成 |
| 输出格式 | 直接回归坐标 + 分类 | 自然语言 JSON |

## 4.2 逐类 AP 对比

表 10: VOC 2007 Test 全 20 类 AP 逐类对比

| 类别 | PLN AP (%) | Gemma AP (%) | 差值 |
|---|---|---|---|
| cat | 89.99 | **90.89** | **+0.90** |
| dog | 83.55 | 82.70 | −0.85 |
| cow | 70.67 | 65.11 | −5.56 |
| bird | 70.46 | 63.71 | −6.75 |
| train | 83.32 | 70.55 | −12.77 |
| person | 66.49 | 53.30 | −13.19 |
| chair | 41.96 | 27.53 | −14.43 |
| sheep | 73.71 | 57.84 | −15.87 |
| bus | 78.24 | 61.72 | −16.52 |
| horse | 83.19 | 66.61 | −16.58 |
| bottle | 41.45 | 24.00 | −17.45 |
| pottedplant | 35.61 | 16.86 | −18.75 |
| motorbike | 79.28 | 59.86 | −19.42 |
| aeroplane | 70.54 | 50.55 | −19.99 |
| bicycle | 81.72 | 61.19 | −20.53 |
| car | 76.30 | 51.87 | −24.43 |
| boat | 48.67 | 24.86 | −23.81 |
| tvmonitor | 66.74 | 39.79 | −26.95 |
| sofa | 66.49 | 36.24 | −30.25 |
| diningtable | 59.97 | 25.08 | −34.89 |
| **mAP** | **68.74** | 51.51 | −17.23 |

图 1: 成功案例：cat 检测。Gemma-4 的蓝色框与 GT 绿色虚线几乎完全重合，对应 cat 类 90.89% AP。大物体 + 语义特征鲜明是 VLM 零样本检测的最优场景。

图 2: 定位偏差案例：person + dog。Gemma-4 正确识别了两个类别，但 person 框包含了整张图（远大于 GT），dog 框也偏大。反映了 2.3B 小模型空间定位精度不足的问题。

图 3: 密集场景漏检案例：多车 + 行人。GT 标注 7 个目标（多辆 car + person），Gemma-4 仅检测到 5 个，遗漏了较小的目标。这是 VLM 自回归生成在密集实例场景下的典型短板。

## 4.3 对比分析

**Gemma-4 接近或超越 PLN 的类别：**cat (+0.90), dog (−0.85)。cat 是唯一 Gemma-4 超过 PLN 的类别（90.89% vs 89.99%），dog 几乎持平。这两个类别在互联网图像中的出现频率极高，VLM 在预训练阶段积累了大量相关视觉-语义知识。值得注意的是，PLN 的 cat AP（89.99%）已经非常高，Gemma-4 能在完全零样本的条件下超过这个数字，说明 VLM 对语义特征鲜明的大物体具备超越专用检测器的识别能力。

**PLN 大幅领先的类别（差距 > 20 点）：**diningtable (−34.89), sofa (−30.25), tvmonitor (−26.95), car (−24.43), boat (−23.81), bicycle (−20.53), aeroplane (−19.99)。失败原因可归纳为三类：

1. **边界模糊的家居物品**（diningtable, sofa）：这类物体的边界在视觉上不清晰，VLM 难以确定精确的 bounding box 范围，框往往过大或过小。PLN 通过有监督训练直接学习了这些类别的边界模式。
2. **密集/远景目标**（boat, car）：图像中出现多个同类小目标时，VLM 倾向于只检测最显著的几个，导致大量漏检。这是自回归生成范式的固有限制——每多输出一个框就多消耗数十个 token。
3. **需要精确边界的物品**（tvmonitor, bicycle）：这些物体的检测质量高度依赖框的精确性，VLM 的坐标回归精度不如经过有监督训练的关键点回归。

## 4.4 范式差异的本质

两种方法在能力维度上呈现清晰的互补特征：

表 11: 两种检测范式的能力维度对比

| 能力维度 | PLN (有监督) | Gemma-4 (零样本) |
|---|---|---|
| 空间定位精度 | 强（直接学习坐标回归） | 弱（离散化文本输出） |
| 语义理解 | 受限于训练集分布 | 强（海量预训练知识） |
| 密集实例检测 | 中（受限于网格容量） | 弱（自回归生成瓶颈） |
| 开放词汇能力 | 无（固定 20 类） | 有（任意自然语言类别） |
| 推理效率 | 高（∼30 ms） | 低（∼4370 ms） |
| 标注成本 | 高（需大量 bbox 标注） | 零 |

PLN 的核心优势在于**精确的空间定位能力**：通过关键点检测和链接回归，直接在特征图上学习坐标映射。这种能力是通过在 16k+ 张标注图像上迭代数万次获得的。

Gemma-4 的核心优势在于**强大的语义理解**：不需要看过任何 VOC 标注就" 知道" cat 长什么样，并能给出 90.89% 的 AP。这种能力来自大规模视觉-语言预训练中积累的通用视觉知识。

17.23 个 mAP 点的差距，本质上是" 通用智能的零样本泛化" 与" 任务特化的精确拟合" 之间的 trade-off。考虑到 PLN 使用了完整的有监督训练（16k+ 张标注图像、200 个 epoch、3.3 小时 GPU 训练），而 Gemma-4 完全是零样本（零标注、零训练、仅一句 prompt），这个差距说明 VLM 的视觉基础能力已经达到了相当可观的水平。

# 5 讨论

## 5.1 51.51% 零样本 mAP 的位置

将 Gemma-4 E2B 的 51.51% 放在 VOC 2007 检测的历史脉络中：

- 随机基线（均匀猜测 + 随机框）：约 1–2% mAP
- DPM v5（2010, 传统特征）：33.7% mAP
- R-CNN（2014, 深度学习开端）：58.5% mAP
- **Gemma-4 E2B（2025, 零样本）：51.51% mAP**
- PLN-ResNet18（2017 架构, 有监督）：68.74% mAP
- Faster R-CNN + ResNet-101（2016, 有监督）：76.4% mAP

一个 2.3B 参数的通用模型，在没有看过任何 VOC 标注的情况下，达到了介于 DPM v5 和 R-CNN 之间的性能。考虑到 DPM v5 是专门为目标检测设计的方法，而 R-CNN 开创了深度学习检测的新纪元，Gemma-4 E2B 的零样本表现处于一个有意义的位置。

## 5.2 瓶颈分析

**空间定位精度**：VLM 生成的坐标是离散化到 1000×1000 网格的整数，理论最大精度约 0.1%。但实际瓶颈不在此——2.3B 模型的视觉编码器分辨率有限，对小目标的定位误差远大于网格精度。IoU 阈值敏感性分析（表 5）直接验证了这一点：mAP 从 0.5

到 0.75 阈值下降 41.7%，远高于有监督检测器的典型降幅（15–25%）。错误分析进一步表明，12.4% 的检测框属于" 定位误差" 类型（正确类别但 IoU 不足），如果框的精度能提升到 IoU≥0.5，mAP 将显著改善。

**密集实例检测**：当一张图中同类物体超过 3–4 个时（如一群人、一排瓶子），模型倾向于只输出最显著的几个。错误分析（表 7）显示 29.7% 的 GT 框未被检测到，其中 person 类漏检 1,278 个（占 person GT 的 28.2%），是漏检最严重的类别。这是 VLM 自回归生成范式的固有限制——每多输出一个框就多消耗数十个 token，而模型在生成过程中会倾向于" 及时停止"。

**推理效率**：4.37s/张的速度使其无法用于任何实时场景。这是 VLM 做检测的根本 trade-off：获得了零样本泛化能力，但牺牲了两个数量级的推理效率。在自动驾驶等对延迟敏感的场景中，这一差距目前是不可接受的。

### 5.3 潜在改进方向

以下方向可能提升零样本 mAP，但本次评测严格遵循零样本约束，未做实验：

1. **更大模型**：Gemma 4 E4B 或 26B-A4B 预期能提升 5–15 个 mAP 点，但推理成本也会相应增加。
2. **CoT prompt**：引导模型先描述图像内容再输出检测框，可能提升小目标召回率，但推理时间会翻倍。
3. **多轮检测**：先检测大物体，再通过追问" 还有其他小物体吗？" 补充遗漏，可能改善密集实例的召回。
4. **框级置信度**：当前使用序列级 log-prob 作为所有框的统一置信度，若能实现框级打分，如通过额外 prompt 让模型为每个框打分，可能改善 PR 曲线排序质量。

## 6 结论

本报告完成了两项工作：Gemma-4 E2B（2.3B 有效参数）在 Pascal VOC 2007 test 集上的零样本目标检测评测，以及与第一阶段 PLN-ResNet18 的跨范式对比分析。主要结论如下：

1. **零样本检测达到可用水平**：mAP@0.5 = 51.51%，mAP@0.75 = 30.05%，4952 张图推理成功率 99.5%，仅 1 张解析失败。
2. **语义理解可超越专用检测器**：对语义特征鲜明的大物体（cat 90.89%, dog 82.70%），Gemma-4 接近甚至超过有监督训练的 PLN。
3. **空间定位是核心短板**：mAP 从 @0.5 到 @0.75 下降 41.7%，远高于有监督检测器的典型降幅。错误分析显示 29.7% 的 GT 被漏检，16.8% 的检测框为背景误检（幻觉），定位误差占 12.4%。
4. **两种范式互补而非替代**：有监督检测器擅长精确定位和高效推理，VLM 擅长语义理解和零样本泛化。17.23 个 mAP 点的差距在快速缩小。

5. **推理效率差距约 145 倍**：自回归生成 vs 前向传播，这是范式差异的必然代价，短期内难以弥合。

从更宏观的视角看，这两个阶段的任务共同描绘了目标检测领域的范式演进图景：从精心设计的专用架构（PLN 的关键点检测 + 链接回归）到通用视觉语言模型的零样本能力（Gemma-4 的 prompt 驱动检测）。前者代表了”为每个任务训练一个专用模型”的传统范式，后者代表了”一个通用模型解决所有视觉任务”的新范式。当前两种范式各有优势，但趋势清晰：随着 VLM 规模增大和推理优化，通用模型的精度天花板在不断抬升，而其零标注、零训练的核心优势是专用检测器无法匹敌的。

# A 实验环境

| 项 | 配置 |
|---|---|
| GPU | NVIDIA RTX 4090 (24GB VRAM) |
| 精度 | BF16 |
| Python | 3.10 |
| PyTorch | 2.1 |
| CUDA | 12.1 |
| Transformers | latest |
| 模型 | google/gemma-4-E2B-it (Apache 2.0) |
| 解码策略 | Greedy (do_sample=False) |
| max_new_tokens | 2048 |

# 参考文献

[1] Gemma Team, Google. *Gemma 4 Technical Report*. 2025.

[2] Everingham, M., Van Gool, L., Williams, C. K., Winn, J., & Zisserman, A. The Pascal Visual Object Classes (VOC) Challenge. *IJCV*, 88(2), 303–338, 2010.

[3] Wang, X., Chen, K., Huang, Z., Yao, C., & Liu, W. Point Linking Network for Object Detection. *arXiv preprint arXiv:1706.03646*, 2017.

[4] Girshick, R., Donahue, J., Darrell, T., & Malik, J. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation. *CVPR*, 2014.

[5] Ren, S., He, K., Girshick, R., & Sun, J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *NeurIPS*, 2015.

[6] He, K., Zhang, X., Ren, S., & Sun, J. Deep Residual Learning for Image Recognition. *CVPR*, 2016.